Université Abdelmalek Essaâdi — Faculté Polydisciplinaire de Larache

Projet scientifique de Master

Complétion de données de Laplace

Filtrage spectral appris, bruit et erreur de modèle

Halhoul Mhamed
Master « Modélisation mathématique et applications et apprentissages » — M2 en cours

Professeur encadrant : Pr. Chakir Tajani

11 octobre 2026 — Édition de travail : visuels institutionnels en attente

Une question comparative, un résultat négatif

Question

Le plafonnement d'un filtre appris améliore-t-il les erreurs extrêmes sous observations partielles ou erreur de hauteur ?

- Onze méthodes affines ; aucun réseau neuronal nécessaire.
- Données synthétiques ; générateur analytique distinct de l'inverse numérique.
- 2 376 000 reconstructions, trois entraînements, zéro échec numérique détecté.
- Le critère préfixé de gain robuste n'est satisfait dans aucun entraînement.

Une exécution réussie n'implique pas une supériorité statistique.

Le transfert amortit exponentiellement les modes

$\Omega = (0,1) \times (0,H)$, $H = 1/4$.

- $\Delta u = 0$; trace supérieure q inconnue.
- Flux nul sur bas et côtés : hypothèse contrôlée.
- 64 moyennes inférieures, éventuellement masquées.

$\phi_0 = 1$, $\phi_k = \sqrt{2}\cos(k\pi x)$.

$$u_k(x,y) = \phi_k(x)\frac{\cosh(k\pi y)}{\cosh(k\pi H)}.$$

$$T_H\phi_k = \operatorname{sech}(k\pi H)\phi_k.$$

$\|\phi_k\| = 1$ mais $\|T_H\phi_k\| \to 0$: inverse non borné.

Le mode constant reste estimé ; le centrage statistique ne le supprime pas.

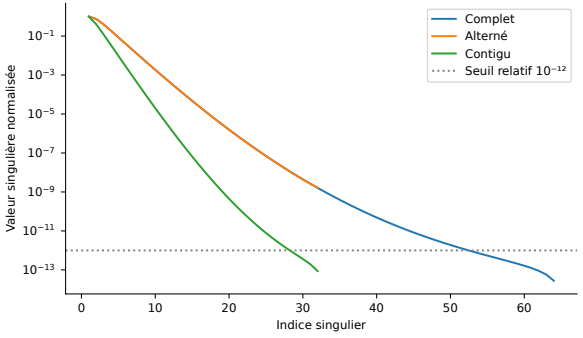
La matrice inverse n'est pas le transfert continu

Capteurs : intervalles de longueur $1/64$.
Masques : complet, pairs, contigu.

$$W = \tfrac{1}{64} I_m, \quad A = Q A_{\mathrm{raw}},$$

$$Q = W^{1/2} / \| W^{1/2} A_{\mathrm{raw}} \|.$$

Bruit après moyenne, avant masque ; calibration entraînement seulement.
Rang numérique : $\sigma_j > 10^{-12} \sigma_1$.



Données | Script | Version GitHub

Séparer implémentation et discrétisation

- Générateur : 128 modes, moyennes analytiques.
- Inverse : 64 modes, différences finies 65×17, fantômes réfléchis.
- Contrôle indépendant : solution modale discrète et raffinement jusqu'à 257×65.

$$\gamma = 2\,\mathrm{asinh}\big((h_y/h_x)\sin(s/2)\big), \quad \rho_k = \frac{\cosh(k\pi H)}{\cosh(N_y\gamma)}\,\frac{s/2}{\tan(s/2)}.$$

Grille	65×17	129×33	257×65
Erreur prévue, $k=8$	0,06851	0,01701	0,00425

Accord discret : 10^{-10} ; erreur continue : $0,005$ au maillage fin. Seuils fixés avant calcul, pas ajustés aux résultats appris.

Le plafond borne une amplification, pas le risque total

$$d = (A + E)c + b + \varepsilon, \qquad \widehat{c} = \mu_c + R(d - \mu_d).$$

Identité exacte, avec $f = A\mu_c - \mu_d$

$$\widehat{c} - c = (RA - I)(c - \mu_c) + R(Ec + b + \varepsilon + f).$$

- Premier terme : biais, noyau et directions rejetées inclus.
- Second : erreur du modèle, queue transmise, bruit et offset.
- Erreur totale : $\|\widehat{q} - q\|^2 = \|\widehat{c} - c\|^2 + \|q_\perp\|^2$.

Pour un filtre diagonal, $\|R\| = \max |g_j|$; H1 et LMMSE demandent la vraie norme matricielle. Réduire la variance peut augmenter le biais.

Ce qui est appris et ce qui est comparé

$$g_* = \frac{\mathrm{Cov}(\beta, z)}{\mathrm{Var}\, z}, \qquad z = \sigma\beta + \varepsilon \implies g_W = \frac{\sigma p}{\sigma^2 p + v}$$

La dernière égalité suppose signal et bruit décorrélés. Moyennes non nulles : estimateur affine. Sous erreur du modèle, gains négatifs possibles.

Références

Tikhonov L2 et H1 ; TSVD ; Wiener ; Wiener plafonné ; LMMSE complet.

Cinq filtres appris

Signé ; signé plafonné ; positif ; positif borné par $1/\sigma$; borné plafonné.

H1 ne commute généralement pas avec $A^T A$. LMMSE exploite les covariances croisées et peut prédire dans le noyau, sans créer d'identifiabilité déterministe.

Validation sans vérité et incertitude par objet

- Trois entraînements de 1000 objets ; 200 validations ; 200 tests nominaux et 200 rugueux.
- Dix répétitions bruitées par objet test ; objets pilote distincts.
- Sept grilles de 20 configurations maximum, quatre méthodes fixes.

$$Q = \frac{1}{N_v} \sum_i \| A\hat{c}(d_i^{(1)}) - d_i^{(2)} \|^2.$$

Deux répétitions indépendantes conditionnellement à l'objet. Le risque prédictif n'est pas le risque inverse : le noyau reste peu visible.

Critère préfixé

À 1 % de bruit : P1 contigu nominal ; P2 complet, hauteur +5 %. Borne du ratio q95 $< 0,90$ et borne du ratio de médiane nominale $< 1,05$.

Bootstrap : 2000 tirages d'objets, quatre bornes à 98,75 % par entraînement. Pas de couverture simultanée des trois entraînements.

Aucun entraînement n'atteint le critère principal

	Jeu 0	Jeu 1	Jeu 2	Cible
P1 ratio q95	0,97096	0,98498	0,98987	—
P1 borne q95	0,99908	1,00117	1,00308	$< 0,90$
P1 borne médiane	1,00127	1,00350	1,00340	$< 1,05$
P2 ratio et borne q95	1,00000	1,00000	1,00000	$< 0,90$

- P1 : baisses ponctuelles modestes, inférieures à l'objectif de 10 %.
- P2 : aucune différence mesurée entre signé et signé plafonné.
- Six évaluations non satisfaites ; aucun ratio bootstrap indéfini.

Résultats primaires | Tirages conservés

Les comparateurs structurés restent essentiels

P1, jeu 0	q95 relatif
Tikhonov L2	0,8026
Tikhonov H1	0,4435
TSVD	0,8569
Wiener	0,7877
Wiener plafonné	0,7731
Appris signé	0,7986
Appris signé plafonné	0,7754
Appris positif	0,8011
Appris borné	0,8011
Appris borné plafonné	0,7764
LMMSE	0,3910

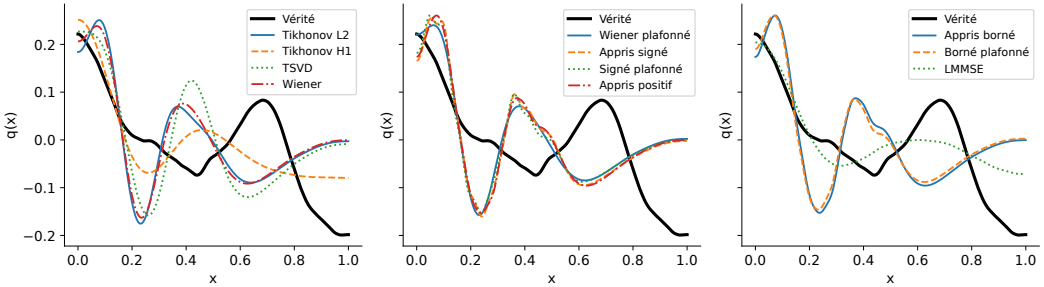
H1 et LMMSE constituent des références fortes dans cette condition.

Une condition ne prouve pas une supériorité universelle.

Toutes les conditions et méthodes

Conserver les cas défavorables

P1, objet 197 : pire erreur moyenne du signé sur dix bruits. Toutes les méthodes, mêmes données, répétition 0.



Zéro échec numérique ne signifie pas reconstruction exacte.

Données | Script | Version GitHub

Portée, coûts et prolongement

Mesures de campagne

Cumul avant analyse : 9,514 s CPU.
Campagne : 4,542 s écoulées.
Pic mémoire : 181,54 Mo.
Résultats au relevé : 110,59 Mo.
2 376 000 reconstructions.

Les rapports cumulatifs distinguent pilote, analyse et figures ; ces chiffres ne promettent pas un coût identique sur une autre machine.

Limites

Rectangle, flux contrôlé, loi synthétique, calibration connue, trois entraînements seulement. Bornes bootstrap approximatives et conditionnelles.

Prolongement unique : choix statistique du plafond sous incertitude d'opérateur. Aucune escalade d'architecture justifiée par l'absence de gain.

Références et Contact

C2 : Tajani et Abouchabaka, *On the data completion problem for Laplace's equation*, 2018.
R01 : Burger et Kabri, régularisation spectrale apprise, 2024.
R02 : Alberti et al., apprentissage du régularisateur Tikhonov, 2021.
R06 : Byrne et Renaut, réglage spectral observationnel, 2023.

Contact

halhoul.mhamed@etu.uae.ac.ma
halhoulmhamed@gmail.com
`https://github.com/halhoulmhamed-droid/inverse-laplace-learning`

Données et code : `0ea95cd7e390c8a478469b36a043a5f99e4fcd10`.
Aucune nouveauté algorithmique ni validation institutionnelle supplémentaire revendiquée.